岭回归中的偏差—方差权衡

一份模板演示：数学、图表、代码与交叉引用

Mainsub
中国科学技术大学
2026 年 10 月 10 日

摘要　本文以岭回归为例演示模板的排版效果。我们在高斯线性模型下推导岭估计量的偏差与方差，说明适度的收缩如何以少量偏差换取方差的显著下降，并用一个模拟实验验证这一结论。

关键词　岭回归；偏差—方差分解；收缩估计

---

1 引言

当设计矩阵 X 的列高度相关时，最小二乘估计 $\hat{\beta} = (X^\top X)^{-1} X^\top y$ 的方差会急剧膨胀。Hoerl 等 (1970) 提出在 $X^\top X$ 的对角线上加入一个正常数，以牺牲无偏性为代价换取更稳定的估计；这一思想后来成为收缩估计（shrinkage estimation）的基石 (Hastie 等, 2009)。关于线性模型的经典理论，可参考 陈希孺 (1999)。[1]

本文的结构如下：第 2 节给出模型与估计量，第 3 节给出数值示例。

2 模型与估计量

2.1 设定

定义 1 (高斯线性模型). 观测满足 $y = X\beta + \varepsilon$，其中 $X \in \mathbb{R}^{n \times p}$ 为固定设计，$\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$。

定义 2 (岭估计量). 对给定的 $\lambda > 0$，岭估计量定义为

$$\hat{\beta}_\lambda = \arg\min_{b \in \mathbb{R}^p} \left\{ \|y - Xb\|_2^2 + \lambda \|b\|_2^2 \right\} = (X^\top X + \lambda I_p)^{-1} X^\top y. \tag{1}$$

2.2 偏差与方差

记 $X = U D V^\top$ 为奇异值分解，$d_1 \geq \cdots \geq d_p > 0$ 为奇异值。

命题 1. 在 定义 1 下，岭估计量的偏差与协方差分别为

$$\mathrm{Bias}(\hat{\beta}_\lambda) = -\lambda \, (X^\top X + \lambda I_p)^{-1} \beta, \tag{2}$$

$$\mathrm{Var}(\hat{\beta}_\lambda) = \sigma^2 \sum_{j=1}^{p} \frac{d_j^2}{(d_j^2 + \lambda)^2} \, v_j v_j^\top. \tag{3}$$

[1] 本文所有数值结果均可由文中代码复现。

因此 $\operatorname{tr}\operatorname{Var}(\hat\beta_\lambda)$ 关于 λ 严格递减，而当 $\beta \neq 0$ 时 $\left\|\operatorname{Bias}\,(\hat\beta_\lambda)\right\|_2^2$ 严格递增。

证明 由 式 (1) 及 $\mathbb{E}y = X\beta$ 得 $\mathbb{E}\hat\beta_\lambda = (X^\top X + \lambda I)^{-1} X^\top X\beta$，两边减去 β 即得 式 (2)。又 $\operatorname{Var}(y) = \sigma^2 I_n$，代入奇异值分解 $(X^\top X + \lambda I)^{-1} X^\top = V\,\operatorname{diag}\left(\,d_j/(d_j^2+\lambda)\right) U^\top$ 即得 式 (3)。

注记 当 $\lambda \to 0$ 时 $\hat\beta_\lambda$ 收敛到最小二乘估计；当 $\lambda \to \infty$ 时 $\hat\beta_\lambda \to 0$。均方误差 $\mathrm{MSE}(\lambda) = \|\operatorname{Bias}\|_2^2 + \operatorname{tr}\operatorname{Var}$ 在两者之间取得最小值。

3 数值示例

我们取 $n = 120$、$p = 6$，设计矩阵的行独立服从 $\mathcal{N}(0, \Sigma)$，其中 $\Sigma_{ij} = 0.6^{|i-j|}$，真实系数 $\beta = (2, -1.5, 1, 0, 0, 0.5)^\top$，$\sigma = 2$。图 1 给出系数随 λ 的收缩路径，表 1 给出由 式 (2) 与 式 (3) 精确计算的风险分解。

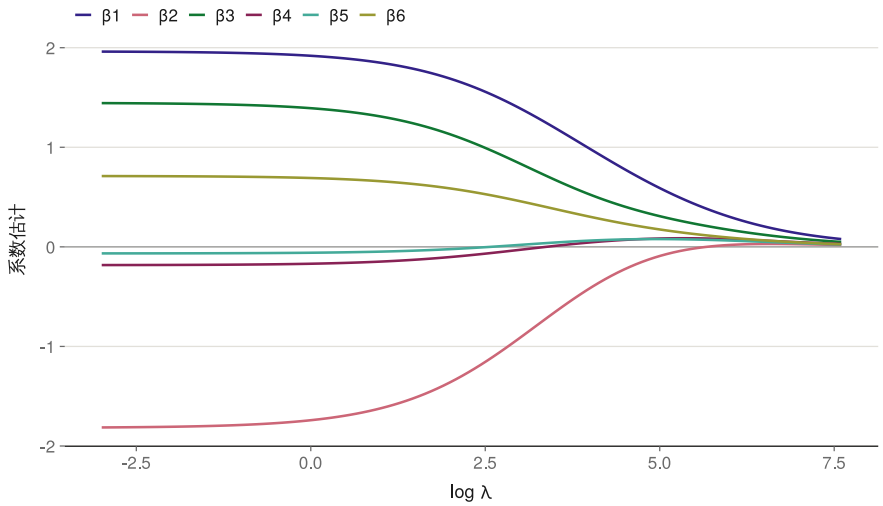


图 1 岭回归的系数路径。随着 λ 增大，所有系数被连续地压向零。

表 1 不同 λ 下的偏差、方差与均方误差

λ	$\|\operatorname{Bias}\|_2^2$	$\operatorname{tr}\operatorname{Var}$	MSE
0	0.000	0.449	0.449
1	0.008	0.424	0.432
2	0.029	0.402	0.430
5	0.148	0.345	0.493
20	1.110	0.194	1.305
100	4.030	0.048	4.078

从 表 1 可以读出：方差随 λ 单调下降，偏差单调上升，与 命题 1 一致；适度的收缩使 MSE 低于最小二乘（$\lambda = 0$），而过度收缩则让偏差主导风险。

计算岭估计量只需要一行线性代数：

```r
ridge <- function(X, y, lambda) {
  p <- ncol(X)
  solve(crossprod(X) + lambda * diag(p), crossprod(X, y))  # 求解正规方程
}
```

4 结论

岭回归说明了统计学中一个反复出现的主题：**无偏并不等于好**。在实践中，λ 通常由交叉验证选取。

参考文献

陈希孺, 1999. 高等数理统计学[M]. 合肥: 中国科学技术大学出版社.

Hastie T, Tibshirani R, Friedman J, 2009. The Elements of Statistical Learning: Data Mining, Inference, and Prediction[M/OL]. 2 版. New York: Springer. DOI:10.1007/978-0-387-84858-7.

Hoerl A E, Kennard R W, 1970. Ridge Regression: Biased Estimation for Nonorthogonal Problems[J/OL]. Technometrics, 12(1): 55-67. DOI:10.1080/00401706.1970.10488634.

A 补充推导

在正交设计 $X^\top X = I_p$ 下，岭估计量是最小二乘估计的简单缩放：

$$\hat{\beta}_\lambda = \frac{1}{1+\lambda}\,\hat{\beta}^{\mathrm{OLS}}, \qquad \mathrm{MSE}(\lambda) = \frac{p\,\sigma^2 + \lambda^2 \|\beta\|_2^2}{(1+\lambda)^2},$$

其最小值在 $\lambda^\star = p\sigma^2 / \|\beta\|_2^2$ 处取得。